TP4 — Cluster Proxmox

Haute disponibilité · Quorum · Migration · PRA

Dimitri ANGELY — M2 Infrastructure Cloud — Juin 2026

Contexte et contraintes

> **Architecture réelle**
> Noeud unique Proxmox (192.168.131.135). Pas de second noeud disponible en environnement de TP. Le TP4 est réalisé en mode PRA documenté (Option E du sujet) avec un cluster mono-noeud démontrant Corosync et le quorum, et un PRA complet backup → panne → restauration → RTO mesuré.

Composant	Détail
Noeud Proxmox	proxmox — 192.168.131.135 — cluster-m2-pve
VM 110 srv-nfs-iscsi	192.168.131.147 — serveur NFS (réutilisé du TP3)
VM 120 zfs-test01	192.168.131.148 — base du clone app-prod01
VM 130 app-prod01	192.168.131.150 — VM critique simulée (nginx)
VM 131 app-prod01-restored	192.168.131.151 — VM restaurée depuis backup PRA
Stockage backup	nfs-backup — NFS sur VM 110 — /srv/nfs/proxmox

Parties 1 & 2 — Préparation et création du cluster

> **Précaution appliquée**
> Vérification de l'état de toutes les VMs du TP3 avant création du cluster. Les VMs 110 et 120 étaient running — aucune interruption constatée après pvecm create.

Vérification pré-cluster

```
qm list
curl http://192.168.131.148
```

```
       110 srv-nfs-iscsi        running    512               8.00 106487
       120 zfs-test01           running    2048              8.00 111869
       121 zfs-test01           running    2048              8.00 122248
zfs-test01 operationnel
```

Création du cluster

> **Limite nom**
> Le nom cluster-m2-proxmox (16 chars) dépasse la limite Corosync de 15 caractères. Renommé en cluster-m2-pve (14 chars).

```
pvecm create cluster-m2-pve
```

```
Corosync Cluster Engine Authentication key generator.
Gathering 2048 bits for key from /dev/urandom.
Writing corosync key to /etc/corosync/authkey.
Writing corosync config to /etc/pve/corosync.conf
Restart corosync and cluster filesystem
```

Partie 3 — Corosync et quorum

État complet du cluster

```
pvecm status
```

```
Cluster information
-------------------
Name:             cluster-m2-pve
Config Version:   1
Transport:        knet
Secure auth:      on

Quorum information
------------------
Date:             Wed Jun 10 00:02:29 2026
Quorum provider:  corosync_votequorum
Nodes:            1
Node ID:          0x00000001
Ring ID:          1.5
Quorate:          Yes

Votequorum information
----------------------
Expected votes:   1
Highest expected: 1
Total votes:      1
Quorum:           1
Flags:            Quorate

Membership information
----------------------
    Nodeid      Votes Name
0x00000001          1 192.168.131.135 (local)
```

Configuration Corosync

```
cat /etc/pve/corosync.conf
```

```
nodelist {
  node {
    name: proxmox
    nodeid: 1
    quorum_votes: 1
    ring0_addr: 192.168.131.135
  }
}
totem {
  cluster_name: cluster-m2-pve
  transport: knet
  secauth: on
  token_coefficient: 125
}
```

Analyse et limites

Paramètre	Valeur	Signification
Transport	knet	Transport moderne Corosync — chiffré

Secure auth	on	Clé authkey générée dans /etc/corosync/
ring0_addr	192.168.131.135	Interface management utilisée — pas d'interface dédiée cluster
token_coefficient	125	Délai avant déclaration d'un noeud mort
Quorate	Yes	Cluster peut prendre des décisions

Limite principale

Corosync utilise l'interface management (192.168.131.135) faute d'interface dédiée. En production, il faudrait un réseau cluster isolé (ex: 10.10.10.x) pour séparer le trafic Corosync du trafic management et éviter qu'une saturation réseau perturbe le quorum.

Tableau des quorums

Noeuds	Votes totaux	Quorum requis	Tolérance panne	Notre cas
1	1	1	Aucune	← Notre situation
2	2	2	Aucune sans qdevice	
3	3	2	1 noeud	Cas idéal TP
4	4	3	1 noeud	

Split-brain

Avec 1 noeud, si le noeud tombe, Corosync s'arrête avec lui — pas de split-brain possible mais pas de HA non plus. Avec 2 noeuds sans qdevice, si un noeud tombe, l'autre perd le quorum (1/2 votes) et se met en standby pour éviter le split-brain. C'est pourquoi 3 noeuds est le minimum recommandé.

Partie 4 — Stockage partagé (réutilisation TP3)

Pourquoi réutiliser le NFS du TP3

Le NFS nfs-backup est un stockage accessible par le réseau, pas lié à un disque local. Dans un vrai cluster multi-noeuds, il suffirait d'exécuter pvesm add nfs nfs-backup sur chaque noeud pour que tous voient les mêmes fichiers. C'est la propriété fondamentale du stockage partagé : indépendance du noeud physique.

```
pvesm status | grep nfs
showmount -e 192.168.131.147
```

```
nfs-backup   nfs   active   7669824   5757120   1501568   75.06%

Export list for 192.168.131.147:
/srv/nfs/proxmox 192.168.131.0/24
```

Limite de l'architecture

Notre serveur NFS tourne sur la VM 110 qui est hébergée sur le seul noeud Proxmox. Si ce noeud tombe, le NFS disparaît en même temps. En production, le serveur NFS serait une appliance physique indépendante (NAS dédié) pour garantir que le stockage backup survive à la panne de n'importe quel noeud.

Partie 5 — VM critique app-prod01

Stratégie

Clone complet de la VM 120 (zfs-test01 — nginx déjà installé) vers VM 130 (app-prod01) sur local-lvm. ZFS-tank étant à 88%, local-lvm est le seul stockage avec suffisamment d'espace.

```
qm clone 120 130 --name app-prod01 --full 1 --storage local-lvm
qm set 130 --ciuser root --cipassword Proxmox2024 --ipconfig0 ip=dhcp
qm cloudinit update 130
qm start 130
# IP obtenue : 192.168.131.150
echo "app-prod01 operationnel" > /var/www/html/index.html
curl http://192.168.131.150
```

```
app-prod01 operationnel

scsi0: local-lvm:vm-130-disk-0,iothread=1,size=8G
```

Warning LVM-thin

Sum of all thin volume sizes (116.54 GiB) exceeds the size of thin pool. Le thin pool est sur-provisionné — 116 Go annoncés pour 112 Go physiques. Risque de saturation si toutes les VMs écrivent simultanément. Surveiller Data% avec lvs.

Parties 6 & 7 — Migration et PRA

> **Pourquoi PRA et pas migration à chaud**
> La migration à chaud nécessite un stockage partagé accessible par les deux noeuds simultanément. local-lvm est un stockage local — il ne peut pas être accédé depuis un autre noeud. Sans second noeud et sans stockage partagé pour les disques VM, on réalise un PRA documenté : backup → restauration sur nouveau VMID.

Ce qu'il faudrait pour une vraie migration à chaud

Condition	Notre situation	Production réelle
Cluster multi-noeuds	1 noeud uniquement	3 noeuds minimum
Stockage partagé disques VM	local-lvm (local)	NFS/Ceph/iSCSI partagé
Réseau Corosync dédié	Interface management	Interface cluster isolée
Fencing	Non configuré	IPMI/iDRAC/PDU
Résultat	PRA manuel	Migration à chaud possible

Partie 8 — Backup PRA

Sauvegarde de app-prod01 avant la panne simulée

```
echo "Backup démarré à : $(date)"
vzdump 130 --storage nfs-backup --mode snapshot --compress zstd
pvesm list nfs-backup | grep 130
```

```
Backup démarré à : Wed Jun 10 12:17:43 AM CEST 2026

INFO: VM Name: app-prod01
INFO: include disk 'scsi0' 'local-lvm:vm-130-disk-0' 8G
INFO: backup mode: snapshot
INFO: backup is sparse: 5.57 GiB (69%) total zero data
INFO: transferred 8.00 GiB in 10 seconds (819.2 MiB/s)
INFO: archive file size: 1.13GB
INFO: Backup job finished successfully

nfs-backup:backup/vzdump-qemu-130-2026_06_10-00_17_44.vma.zst  backup  1209441595
130
```

Partie 9 — Panne contrôlée

> **Précaution appliquée**
> Backup vérifié avant déclenchement de la panne. Timestamps notés précisément pour mesure du RTO. Panne par arrêt brutal de la VM (simule une panne serveur, pas un arrêt propre).

```
echo "Panne déclenchée à : $(date)"
qm stop 130 --skiplock 1
sleep 3
curl --max-time 3 http://192.168.131.150 || echo "SERVICE INDISPONIBLE —
$(date)"
```

```
Panne déclenchée à : Wed Jun 10 12:18:00 AM CEST 2026
curl: (28) Connection timed out after 3006 milliseconds
SERVICE INDISPONIBLE — Wed Jun 10 12:18:08 AM CEST 2026
```

Partie 10 — Reprise de service

Restauration depuis backup NFS

```
echo "Reprise démarrée à : $(date)"
qmrestore nfs-backup:backup/vzdump-qemu-130-2026_06_10-00_17_44.vma.zst 131 \
  --storage local-lvm --unique 1
qm set 131 --name app-prod01-restored
qm start 131
# IP obtenue : 192.168.131.151
curl http://192.168.131.151
echo "Service restauré à : $(date)"
```

```
total bytes read 8589934592, sparse bytes 5981405184 (69.6%)
space reduction due to 4K zero blocks 2.81%

app-prod01 operationnel

Service restauré à : Wed Jun 10 12:24:22 AM CEST 2026
```

> **RTO mesuré**
> Panne : 00:18:00 → Service restauré : 00:24:22 → RTO = 6 minutes 22 secondes en conditions de laboratoire optimales (VM quasi vide, backup local, commandes préparées). RTO réaliste en production : 30 min à 2h selon taille VM, réseau et procédure de décision.

Validation finale — Scénario complet

```
echo "=== CLUSTER ===" && pvecm status | grep -E "Name|Quorate|Nodes"
echo "=== QUORUM ===" && corosync-quorumtool -s | grep -E
"Expected|Total|Quorum"
echo "=== COROSYNC ===" && systemctl is-active corosync
echo "=== STOCKAGE NFS ===" && pvesm status | grep nfs
echo "=== VM SOURCE ===" && qm list | grep 130
echo "=== VM RESTAUREE ===" && qm list | grep 131
echo "=== SERVICE ORIGINAL ===" && curl --max-time 3 http://192.168.131.150 ||
echo "STOPPED"
echo "=== SERVICE RESTAURE ===" && curl http://192.168.131.151
echo "=== BACKUP ===" && pvesm list nfs-backup | grep 130
```

```
=== CLUSTER ===
Name:             cluster-m2-pve
Nodes:            1
Quorate:          Yes
=== QUORUM ===
Expected votes:   1
Total votes:      1
Quorum:           1
=== COROSYNC ===
active
=== STOCKAGE NFS ===
nfs-backup   nfs   active   7669824   6938240   320512   90.46%
=== VM SOURCE ===
       130 app-prod01           stopped    2048               8.00 0
=== VM RESTAUREE ===
       131 app-prod01-restored  running    2048               8.00 153444
=== SERVICE ORIGINAL ===
curl: (7) Failed to connect to 192.168.131.150 port 80
STOPPED (panne simulée)
=== SERVICE RESTAURE ===
app-prod01 operationnel
=== BACKUP ===
nfs-backup:backup/vzdump-qemu-130-2026_06_10-00_17_44.vma.zst  backup  1209441595
130
```

Partie 11 — Analyse HA / PRA / Backup

Mécanisme	Automatique	RTO typique	RPO	Protège contre
HA Proxmox	Oui	2-5 min	0 (VM live)	Panne noeud
PRA manuel	Non	30 min - 2h	Dernier backup	Panne grave
Backup seul	Planifié	Variable	Fréquence backup	Erreur humaine

Ce que HA ne protège pas

HA redémarre une VM sur un autre noeud — elle ne protège pas contre : suppression de fichiers dans la VM, corruption applicative (ransomware, bug), mauvaise configuration déployée, erreur humaine. HA + Backup = couverture complémentaire et nécessaire.

RTO réaliste vs RTO de laboratoire

Notre RTO mesuré de 6 minutes 22 secondes correspond à une restauration en conditions de laboratoire optimales : VM quasi vide (69% de zéros), backup sur NFS local, commandes préparées à l'avance, réseau 1 Gbps. En production réelle avec des VMs de 50-100 Go de données réelles, un stockage réseau distant et une procédure de décision humaine incluant détection, alerte et validation, un RTO réaliste pour ce type de PRA serait de 30 minutes à 2 heures.

Pour descendre sous les 5 minutes de manière fiable et automatique, il faudrait une HA complète avec cluster 3 noeuds, stockage partagé temps réel (Ceph ou iSCSI), et fencing IPMI pour éviter le split-brain.

Synthèse — Architecture et limites

Élément	État	Commande de preuve
Cluster cluster-m2-pve	☑ Créé	pvecm status → Name + Quorate: Yes
Corosync actif	☑ Running	systemctl is-active corosync → active
Quorum mono-noeud	☑ Documenté	Expected=1, Total=1, Quorum=1
Réseau Corosync	☑ Identifié	ring0_addr: 192.168.131.135:5405
Stockage NFS partagé	☑ Actif	pvesm status → nfs-backup active
VM app-prod01	☑ Opérationnelle	curl 192.168.131.150 → app-prod01 operationnel
Backup PRA	☑ Créé	vzdump-qemu-130-*.vma.zst sur NFS

Panne contrôlée	☑ Démontrée	curl timeout → SERVICE INDISPONIBLE
Reprise de service	☑ Réussie	VM 131 running → service OK
RTO mesuré	☑ 6min 22s	00:18:00 → 00:24:22 (lab)
RPO identifié	☑ Documenté	Backup 2026_06_10-00_17_44
Limites documentées	☑ Expliquées	Mono-noeud, stockage local, NFS sur VM